GraphBudget

SGLang 确定性解码性能优化

技术报告 | 2026 年 10 月 28 日 | SGLang v0.5.9

+72.4%	5	595
吞吐配对提升中位数	组交错 A/B	项 GEMM 与重排检查

摘要。 GraphBudget 面向 SGLang 确定性解码（Deterministic Decode）的性能问题，研究可选的 BF16 Small-M GEMM 执行优化。项目参考 SGLang PR #42145 中的分块几何方案，在固定 SGLang v0.5.9 Triton 路径上完成适配、原生回退、正确性与请求级性能验证。在 RTX 5070 Laptop、Qwen2.5-0.5B-Instruct BF16 及限定负载下，五组交错配对的有效输出吞吐提升中位数为 **72.4%**。本结果只属于明确的模型、硬件与执行配置，不代表跨模型、跨框架或生产服务的通用收益。原始 CUDA Graph 成本策略与 Decode Metadata 候选没有确立稳定的增量收益，相关实验结果单独保留。

1 问题与技术目标

在推理 Decode 阶段，部分 BF16 矩阵乘的输出行数 M 很小，传统较大的矩阵 Tile 可能不匹配实际工作负载。当前实验版本的确定性 SGLang 使用 persistent Triton GEMM。研究目标是在不改变既有 FP32 累加和融合 Bias 数值语义、也不放宽原生执行安全条件的前提下，验证小 M 分块方案是否能改善真实请求完成效率。

本项目的可量化性能结果来自 **Small-M GEMM 路径适配**。其 Tile 思路来源于 bill-h-lin 的 SGLang PR #42145；本项目完成的是对固定执行版本的适配、路径接入、验证与测量，不将其称为自创 GEMM 算法，也不声称获得上游合并。

2 实现范围与数值契约

性能分支为 `_matmul_persistent_triton` 引入可关闭的候选路径。只有显式启用开关、输入为 BF16、$0 < M \le 16$、$K \bmod 64 = 0$、$N \bmod 128 = 0$ 且相关内层 Stride 满足条件时，才选择 $B_M = 16$、$B_N = 64$、$B_K = 128$、四个 Warp、一个程序处理一个输出 Tile 的方案；其余调用沿用原生实现。

候选和基线共享既有 persistent Triton GEMM 计算结构，保留 FP32 累加与 fused-bias 的计算次序，避免用更快但不满足当前确定性契约的路径替代。改动不会引入在线 CUDA Graph 重新捕获、新的请求准入调度器或 GPU 到 CPU 的逐步同步读取。原有图执行与安全判断仍由 SGLang 负责。

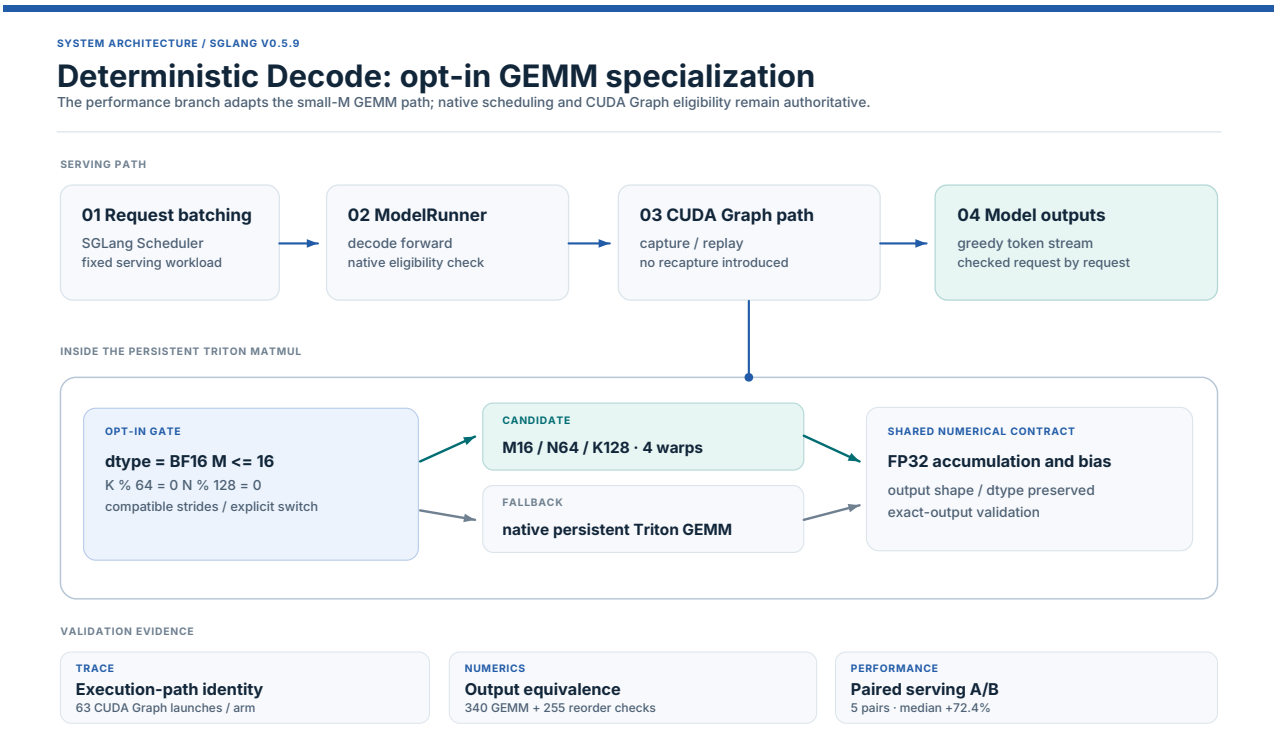


图 1: 推理执行边界与 Small-M 路径。Kernel 选择发生在实际 Launch 准备或 Graph Capture 阶段，已捕获的 CUDA Graph 在 Replay 时不会逐 Token 重新动态选路。

3 实验环境与比较协议

表 1: 固定版本与正式实验条件

项目	条件
运行环境	SGLang v0.5.9（基线 SHA：`bbe9c7e...`），RTX 5070 Laptop，WSL
软件栈	PyTorch 2.9.1+cu128，Triton 3.5.1，确定性 Triton
模型	Qwen2.5-0.5B-Instruct，BF16，TP=1，贪心解码
服务限制	最多 16 个正在执行的请求；Graph 捕获大小 $[1, 2, 4, 8, 12, 16]$；关闭 Overlap
正式工作负载	每个实验臂 256 个固定请求，每个请求输出 128 Token
对照协议	五组独立服务进程交错配对：AB、BA、AB、BA、AB
核心指标	有效输出 Tokens/s；先计算每组相对变化，再取中位数

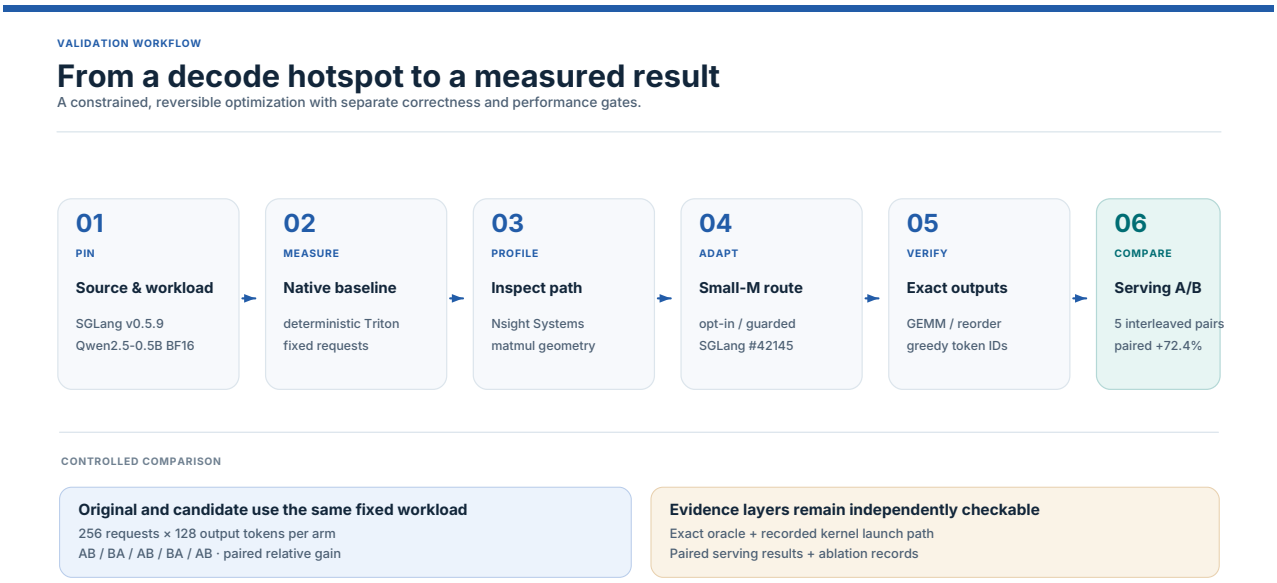


图 2: 从固定环境、原生基线、性能剖析、候选适配，到数值验证和请求级 A/B。原预算策略与元数据优化作为独立消融结果记录。

4 端到端吞吐结果

表 2: 五组正式配对结果

组次	原生路径（Tokens/s）	候选路径（Tokens/s）	组内相对变化
1	1,164.15	2,007.24	+72.42%
2	1,096.61	1,783.15	+62.61%
3	1,122.35	2,087.16	+85.96%
4	1,128.60	1,933.98	+71.36%
5	1,135.00	2,023.29	+78.26%
		配对相对变化中位数	**+72.42%**

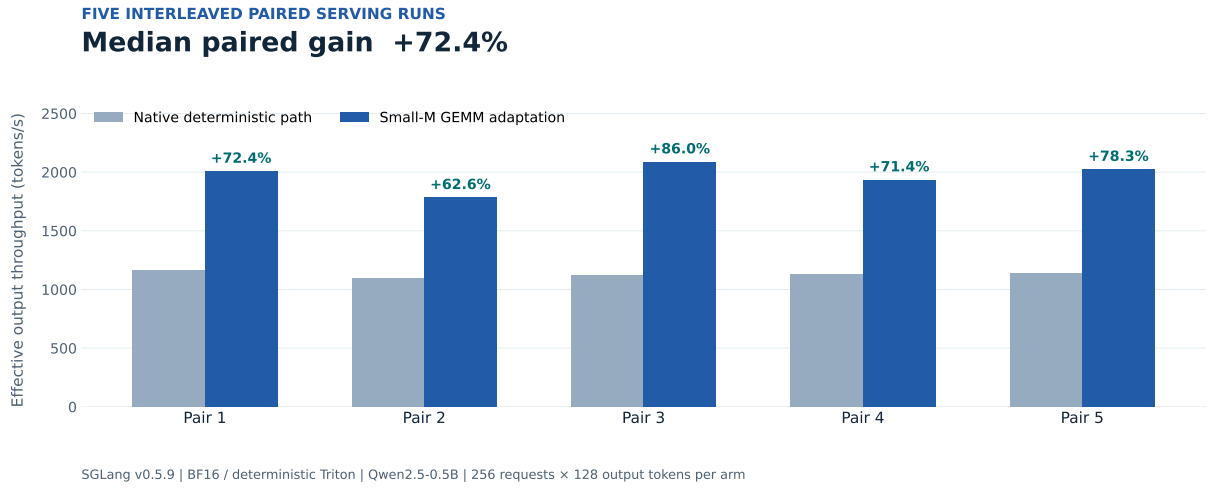


图 3: 固定请求负载下的原生确定性路径与 Small-M GEMM 候选。图中百分比表示各组配对相对变化，不能理解为与最新 SGLang 默认服务路径相比的通用加速。

五组主负载性能变化均为正；前、后 A/A 吞吐变化分别为 +7.9% 与 +8.8%。这两组 A/A 只能表示有限的噪声观测，不是置信区间。主负载的结果不能自动推广到开放到达率、不同模型或不同执行硬件。

5 正确性与执行路径证据

最终实际加载的 GEMM 源码通过 340 项数值检查，覆盖若干模型相关形状和 $M = 1 \dots 17$；其中 170 项具有独立精确 CPU 参考。全部 340 项与原生输出逐位一致。另外 255 项检查覆盖行重排、跨 Batch 复用和随机 Bias。正式请求输出在所测条件下逐 Token 一致。上述检查不代表任意形状、任意设备都已经验证。

Nsight Systems 记录中,两条执行臂均观察到 63 次 `cudaGraphLaunch`。原生臂的 6,305 次 `matmul_kernel_persist` 活动均采用 256 Threads/Block；候选臂中 6,113 次采用 128 Threads/Block，另 192 次仍为 256。这表明目标 GEMM 的实际启动配置已经发生变化。Trace 用于路径诊断，正式吞吐结论使用未开启 Profiling 的独立请求测量。

6 负结果、局限与下一步

表 3: 单独成立的负结果与验证边界

实验方向	结论及其边界
原 CUDA Graph 成本分派	相对公平静态设置没有稳定增量收益，继续采用原生分派。
Metadata 预分配	两个对照区块分别为 +0.8%、−1.0%；没有建立稳定性能增益。
Metadata Fusion	分别为 −3.4%、−6.1%，不作为正向优化成果。
Holdout 首 Token 延迟	TTFT p50 配对变化方向不一致，中位数 +21.5%（更差），不能宣称普遍降低延迟。
显存与启动	未确立 VRAM 节省、KV 扩容或冷启动加速；启动实验存在文件系统差异。
硬件性能计数器	Nsight Compute 因 `ERR_NVGPUCTRPERM` 未取得相关计数器；不推断实际 Occupancy 或带宽提升。

负结果否定的是具体成本策略和元数据候选的性能假设，**不否定已独立完成验证的 GEMM 适配结果**。后续应通过剖析确定新的高贡献性能热点，再决定是否进行独立优化。对跨模型、跨 GPU 的泛化验证应单独设计实验；目前没有相应结论。

7 复现入口与来源

公开仓库 提供固定性能提交、SGLang Patch、机器可读的 A/B 汇总和运行环境说明。复现实验需严格对齐依赖版本、模型修订和请求参数；单组重跑不等于重现五组正式结果。

1. bill-h-lin，SGLang PR #42145：Small-M BF16 GEMM 的 Tile 思路与来源。
2. GraphBudget 原始性能记录：固定条件、正式配对、消融和限制。
3. SGLang Runtime 集成补丁：路径门控、数值契约和观测点。
4. 第三方许可与归属声明。